

Imię i nazwisko studenta: Krystian Chmielewski

Nr albumu: 172070

Poziom kształcenia: studia drugiego stopnia

Forma studiów: stacjonarne

Kierunek studiów: Informatyka

Specjalność: Uczenie maszynowe

Imię i nazwisko studenta: Tymoteusz Paliński

Nr albumu: 188764

Poziom kształcenia: studia drugiego stopnia

Forma studiów: stacjonarne

Kierunek studiów: Informatyka

Specjalność: Uczenie maszynowe

PRACA DYPLOMOWA MAGISTERSKA

Tytuł pracy w języku polskim: Ocena jakości wyszukiwania informacji w bazach specjalistycznych za pomocą zapytania głosowego przetworzonego na tekst (speech-to-text) z wykorzystaniem uczenia głębokiego

Tytuł pracy w języku angielskim: Evaluation of Information Retrieval Quality in Specialized Databases Using Voice Queries Converted to Text (Speech-to-Text) with Deep Learning

Opiekun pracy: prof. dr hab. inż. Bożena Kostek

Spis treści

Streszczenie

Niniejsza praca analizuje możliwości najnowocześniejszych modeli w dziedzinie automatycznego rozpoznawania mowy (ASR) w zakresie uczenia się semantycznych reprezentacji danych w wielu językach oraz w ramach słownictwa specjalistycznego. Po pierwsze, przeprowadzono analizę reprezentacji przestrzeni ukrytej w różnych modelach ASR, dostarczając wyczerpującą ocenę semantyczności tych reprezentacji na podstawie osadzeń ich transkrypcji (przestrzeni ukrytych) wygenerowanych przez trzy różne modele osadzania tekstu. Następnie przedstawiane jest nowatorskie, kompleksowe podejście do wielomodalnego wyszukiwania dokumentów oparte na istniejących modelach ASR, którego jakość oceniana jest na różnych zbiorach danych. Na koniec wykorzystujemy wcześniejsze ustalenia do stworzenia kompleksowego systemu wyszukiwania dokumentów dla specjalistycznych danych medycznych w języku polskim.

Abstract

This study examines the capabilities of the state of the art models in the field of automatic speech recognition (ASR) to learn semantic representations of data across several languages and specialized vocabulary. Firstly, an examination of latent space representations across different ASR models is performed, delivering an exhaustive evaluation of semanticity of latent space representations of speech based on the semantic embeddings of their transcripts delivered by three different text embedding models. Afterwards, a novel end to end framework for multi-modal document retrieval based on existing ASR models is proposed, which is evaluated on different datasets. Lastly, we employ the previous findings in constructing an end to end document retrieval system for specialized medical data in Polish.

1 Wprowadzenie

1.1 Kontekst i motywacja

1.1.1 Wyszukiwanie informacji w bazach specjalistycznych

Tradycyjne systemy wyszukiwania informacji opierały się na modelu boolowskim (ang. *Boolean Information Retrieval*), w którym zapytania formułowane są za pomocą operatorów logicznych AND, OR oraz NOT [salton1983introduction]. Podejście to, choć precyzyjne w założeniach teoretycznych, wymaga od użytkownika znajomości składni zapytań i nie uwzględnia zjawisk językowych takich jak synonimia czy polisemia [manning2008introduction]. Ograniczenia te doprowadziły do rozwoju systemów typu *free text retrieval*, w których zapytania formułowane są w języku naturalnym, a dokumenty rankingowane według stopnia dopasowania [robertson2009probabilistic].

Ewolucja ta jest szczególnie widoczna w kontekście specjalistycznych baz danych, takich jak PubMed czy MEDLINE, które początkowo opierały się na kontrolowanych słownikach (MeSH - *Medical Subject Headings*) i zapytaniach boolowskich [lu2011pubmed]. Współczesne interfejsy tych systemów oferują jednak wyszukiwanie w języku naturalnym z automatycznym rozszerzaniem zapytań o synonimy i terminy pokrewne, co znacząco obniża barierę wejścia dla użytkowników końcowych - lekarzy i badaczy nieposiadających przygotowania z zakresu informatologii. Dalszy postęp w tej dziedzinie wiąże się z zastosowaniem modeli uczenia głębokiego do reprezentacji semantycznej tekstu oraz architektur typu RAG (ang. *Retrieval-Augmented Generation*), które zostały szczegółowo omówione w rozdziale 2.

1.1.2 Rola przetwarzania mowy w wyszukiwaniu informacji

Współczesne modele automatycznego rozpoznawania mowy (ang. *Automatic Speech Recognition*, ASR) umożliwiają formułowanie zapytań do systemów wyszukiwania informacji za pomocą mowy, co jest szczególnie istotne w środowiskach klinicznych, gdzie ręczne wprowadzanie tekstu jest niepraktyczne. Modele takie jak Whisper [whisper], Wav2Vec 2.0 [baevski2020wav2vec] czy HuBERT [hsu2021hubert] osiągają wysoką jakość transkrypcji dla wielu języków, jednak w podejściu kaskadowym (ASR → embedding tekstowy → wyszukiwanie) błędy transkrypcji propagują się do kolejnych etapów, obniżając jakość wyników wyszukiwania. Szczegółowy przegląd architektury i możliwości tych modeli przedstawiono w rozdziale 2.

1.1.3 Ograniczenia modeli dla języka polskiego i domen specjalistycznych

Współczesne modele uczenia głębokiego są w przeważającej mierze trenowane na danych w języku angielskim. Zbiory danych wykorzystywane do pretrainingu dużych modeli językowych, takie jak Common Crawl, Wikipedia czy arXiv, charakteryzują się znaczącą nadreprezentacją treści anglojęzycznych [joshi2020state]. Szacuje się, że język angielski stanowi ponad 90% danych treningowych wielu popularnych modeli, mimo że jest językiem ojczystym jedynie dla około 5% światowej populacji [bender2021dangers].

Nierównowaga ta ma istotne konsekwencje dla jakości modeli w kontekście języków innych niż angielski. Języki regionalne, w tym język polski, są klasyfikowane jako języki o średnich lub niskich zasobach (ang. *mid-resource* lub *low-resource languages*) [joshi2020state]. Modele wielojęzyczne, takie jak mBERT [devlin2019bert], XLM-RoBERTa [conneau2020unsupervised]

czy Whisper [**whisper**], stanowią próbę rozwiązania tego problemu, jednak badania empiryczne wskazują, że ich jakość dla języków innych niż angielski jest systematycznie niższa [**wu2020all**], szczególnie w zadaniach wymagających znajomości specjalistycznej terminologii.

Ograniczenia modeli ogólnego przeznaczenia w kontekście domen specjalistycznych wynikają nie tylko z nierównowagi językowej, ale również z charakteru danych treningowych. Modele ASR są trenowane głównie na podcastach, filmach i nagraniach z platformy YouTube [**whisper**], które rzadko zawierają specjalistyczną terminologię medyczną. Analogiczny problem dotyczy modeli embeddingowych, których reprezentacje wektorowe terminów specjalistycznych mogą nie odzwierciedlać poprawnie ich znaczenia w kontekście domenowym [**lee2020biobert**]. Istnieją rozwiązania w postaci modeli dostosowanych do konkretnych domen, jednak dotyczą one przede wszystkim języka angielskiego (zob. rozdział 2).

Kluczowym wyzwaniem pozostaje ograniczona dostępność specjalistycznych zbiorów danych dla języka polskiego. Podczas gdy dla języka angielskiego istnieją obszerne zbiory tekstów medycznych, takie jak MIMIC-III [**johnson2016mimic**] czy PubMed, dla języka polskiego brakuje porównywalnych zasobów. Dokumentacja medyczna w języku polskim jest rozproszona, często niedostępna ze względów prawnych i wymaga pracochłonnej anonimizacji przed wykorzystaniem do celów badawczych. Sytuacja ta tworzy błędne koło: brak danych uniemożliwia trening wysokiej jakości modeli, co z kolei utrudnia automatyzację procesów, które mogłyby wspomóc tworzenie i przetwarzanie takich zbiorów.

1.2 Proponowane podejście

1.2.1 System wyszukiwania oparty na transkrypcji audio i wektorowej bazie danych

Klasyczna architektura systemu wyszukiwania informacji na podstawie zapytań głosowych opiera się na sekwencyjnym przetwarzaniu sygnału audio przez oddzielne moduły. Podejście to można określić jako pipeline kaskadowy, w którym każdy etap przetwarza dane wyjściowe etapu poprzedniego.

W pierwszym etapie sygnał audio jest przetwarzany przez model ASR, taki jak Whisper [**whisper**] lub jego wersja dostrojona do domeny specjalistycznej. Wynikiem tego etapu jest transkrypcja tekstowa zapytania użytkownika. Następnie tekst jest przekształcany przez model embeddingowy w reprezentację wektorową. Modele takie jak Sentence-BERT [**reimers2019sentence**] czy Jina Embeddings [**gunther2023jina**] generują wektor o stałym wymiarze, reprezentujący semantyczną treść zapytania.

Uzyskany wektor zapytania jest porównywany z wektorami dokumentów zindeksowanych w wektorowej bazie danych. Systemy takie jak FAISS [**johnson2019billion**] czy Milvus [**wang2021milvus**] umożliwiają efektywne wyszukiwanie przybliżonych najbliższych sąsiadów (ang. *approximate nearest neighbor search*) w przestrzeniach wielowymiarowych. Na podstawie miary podobieństwa system zwraca k dokumentów najbardziej zbliżonych semantycznie do zapytania.

Opcjonalnie architektura może być rozszerzona o komponent generacyjny zgodnie ze wzorcem RAG [**lewis2020retrieval**]. W takim przypadku wyszukane dokumenty stanowią kontekst dla dużego modelu językowego, który generuje odpowiedź w języku naturalnym, syntetyzując informacje z wielu źródeł.

TODO: tu diagram

Architektura kaskadowa oferuje szereg zalet praktycznych. Transkrypcja tekstowa stanowi dodatkowy produkt przetwarzania, który może być wykorzystany do celów dokumentacyjnych lub archiwalnych. Użytkownik ma możliwość weryfikacji i ewentualnej korekty

rozpoznanego tekstu przed wykonaniem wyszukiwania, co zwiększa kontrolę nad procesem. Transparentność systemu ułatwia debugowanie. Każdy etap może być analizowany niezależnie, co pozwala na identyfikację źródła ewentualnych błędów. Ponadto architektura ta wykorzystuje sprawdzone, dostępne komponenty, które mogą być wymieniane niezależnie w miarę postępu technologicznego.

Podjęcie kaskadowe wiąże się jednak z istotnymi ograniczeniami. Dwuetapowe przetwarzanie wprowadza dodatkową latencję, co może być problematyczne w zastosowaniach wymagających odpowiedzi w czasie rzeczywistym. Błędy popełnione na etapie transkrypcji propagują się do kolejnych etapów. Niepoprawnie rozpoznany termin specjalistyczny skutkuje generacją błędnego embeddingu, a w konsekwencji nieadekwatnymi wynikami wyszukiwania.

Ponadto redukcja sygnału audio do tekstu prowadzi do utraty informacji. Cechy prozodyczne, takie jak intonacja, tempo mowy czy wahania, mogą nieść informację o pewności lub intencji mówiącego. Informacje te są tracone w procesie transkrypcji. Przykładowo, termin medyczny wymówiony z wahaniami może wskazywać na niepewność diagnostyczną, jednak po transkrypcji jest nieodróżnialny od tego samego terminu wymówionego z pewnością.

1.2.2 Proponowany system wyszukiwania informacji oparty na reprezentacji cech ukrytych modelu ASR

Alternatywnym podejściem jest bezpośrednie wykorzystanie reprezentacji ukrytych generowanych przez enkoder modelu ASR do wyszukiwania informacji, z pominięciem etapu transkrypcji tekstowej. Koncepcja ta, określana jako Speech-to-Retrieval, opiera się na założeniu, że reprezentacje ukryte modeli ASR zawierają informację semantyczną wystarczającą do realizacji zadań wyszukiwania.

Modele takie jak Wav2Vec 2.0 [baevski2020wav2vec], HuBERT [hsu2021hubert] czy enkoder modelu Whisper generują w warstwach pośrednich reprezentacje wektorowe segmentów audio. Reprezentacje te, będące wynikiem przetwarzania przez głębokie sieci neuronowe, kodują informację na różnych poziomach abstrakcji. Warstwy bliższe wejściu reprezentują cechy akustyczne niskiego poziomu, podczas gdy warstwy głębsze mogą kodować informację fonologiczną, leksykalną, a potencjalnie również semantyczną [pasad2021layer].

Architektura proponowanego systemu składa się z enkodera ASR, warstwy projekcji oraz wektorowej bazy danych. Sygnał audio jest przetwarzany przez enkoder, który generuje sekwencję reprezentacji ukrytych. Sekwencja ta jest następnie agregowana (np. przez uśrednienie lub mechanizm uwagi) i przekształcana przez warstwę projekcji do przestrzeni wektorowej zgodnej z embeddingami tekstowymi dokumentów. Uzyskany wektor służy do wyszukiwania w bazie wektorowej analogicznie jak w architekturze kaskadowej.

TODO: tu diagram

Kluczowym elementem architektury jest warstwa projekcji (adapter), której zadaniem jest mapowanie reprezentacji z przestrzeni enkodera ASR do przestrzeni embeddingów tekstowych. Trening tego komponentu wymaga zbioru par (audio, tekst) wraz z odpowiadającymi im embeddingami tekstowymi. Celem optymalizacji jest minimalizacja odległości między projekcją reprezentacji audio a embeddingiem odpowiadającego tekstu.

Potencjalne zalety proponowanego podejścia obejmują redukcję latencji poprzez eliminację etapu dekodowania tekstu oraz możliwość wykorzystania informacji akustycznej niedostępnej w transkrypcji. Ponadto architektura end-to-end otwiera możliwość wspólnej optymalizacji komponentów retrieval i ASR, co może prowadzić do lepszego dostosowania reprezentacji do zadania wyszukiwania.

Podejście to wiąże się jednak z istotnymi wyzwaniami. Brak transkrypcji utrudnia weryfikację i interpretację działania systemu przez użytkownika. Wyjaśnialność systemu jest ograniczona, ponieważ trudniej jest zrozumieć, dlaczego system zwrócił określone dokumenty. Trening warstwy projekcji wymaga odpowiednio dużego zbioru danych. Ponadto modele ASR nie były pierwotnie trenowane z myślą o zadaniach wyszukiwania informacji, co może ograniczać jakość reprezentacji semantycznych.

1.2.3 Pytania badawcze

Porównanie przedstawionych architektur prowadzi do sformułowania pytań badawczych stanowiących przedmiot niniejszej pracy:

1. Czy reprezentacje ukryte generowane przez modele ASR zawierają wystarczającą informację semantyczną do realizacji zadań wyszukiwania informacji?
2. Jak jakość wyszukiwania opartego na reprezentacjach ukrytych wypada w porównaniu z podejściem kaskadowym (ASR $\rightarrow$ embedding tekstowy)?
3. Jaki wpływ na jakość obu podejść ma język zapytania (polski vs. angielski) oraz domena (terminologia medyczna vs. język ogólny)?
4. Które warstwy modeli ASR generują reprezentacje najbardziej przydatne do zadań wyszukiwania semantycznego?

Odpowiedzi na te pytania pozwolą na ocenę praktycznej przydatności podejścia Speech-to-Retrieval w kontekście specjalistycznych systemów wyszukiwania informacji dla języka polskiego.

1.3 Struktura pracy

Dalsza część pracy jest zorganizowana w następujący sposób. Rozdział 2 zawiera przegląd literatury obejmujący systemy wyszukiwania informacji, modele embeddingowe, architekturę RAG oraz współczesne modele ASR. W rozdziale 3 przedstawiono badania nad semantycznością reprezentacji wektorów cech modeli ASR. Rozdział 4 opisuje ewaluację architektur dopasowania reprezentacji latentnych modeli ASR i modeli embeddingowych. W rozdziale 5 zaprezentowano zaprojektowany system wyszukiwania informacji wykorzystujący opracowane architektury. Rozdział 6 zawiera podsumowanie i wnioski.

2 Przegląd

2.1 Systemy wyszukiwania informacji

2.1.1 Ewolucja od wyszukiwania boolowskiego do semantycznego

Tradycyjne systemy wyszukiwania informacji opierały się na modelu boolowskim, w którym wynik wyszukiwania ma charakter binarny, bez uwzględnienia stopnia dopasowania dokumentu do intencji użytkownika. Rozwój systemów typu *free text retrieval* wprowadził miary takie jak TF-IDF (ang. *Term Frequency-Inverse Document Frequency*), umożliwiające kwantyfikację istotności terminów w kontekście kolekcji dokumentów [sparckjones1972statistical, salton1988term]. Współczynnik TF-IDF przypisuje wyższą wagę terminom występującym często w danym dokumencie, ale rzadko w całej kolekcji, co pozwala na identyfikację słów kluczowych charakterystycznych dla treści dokumentu.

Klasyczne metody reprezentacji tekstu, takie jak model *Bag of Words* (BoW) czy TF-IDF, traktują jednak dokument jako nieuporządkowany zbiór słów, ignorując ich kolejność oraz zależności kontekstowe [harris1954distributional]. Podejście to, określane jako reprezentacja leksykalna, nie uwzględnia podobieństwa semantycznego między wyrażeniami - terminy „zawał serca” i „myocardial infarction” są traktowane jako całkowicie odrębne jednostki, mimo identycznego znaczenia.

2.1.2 Modele embeddingowe

Przełomem w kierunku reprezentacji semantycznej było wprowadzenie modelu Word2Vec [mikolov2013efficient, mikolov2013distributed], który mapuje słowa do gęstej przestrzeni wektorowej o niższym wymiarze (typowo 100-300 wymiarów). W przestrzeni tej słowa o podobnym znaczeniu lub występujące w podobnych kontekstach są reprezentowane przez wektory bliskie sobie według miary odległości, takiej jak podobieństwo kosinusowe. Model Word2Vec opiera się na hipotezie dystrybucyjnej Harrisa [harris1954distributional], zgodnie z którą znaczenie słowa jest determinowane przez kontekst jego występowania.

Ograniczeniem modelu Word2Vec jest generowanie statycznych embeddingów - każde słowo posiada pojedynczą reprezentację wektorową niezależnie od kontekstu użycia. Problem ten rozwiązują kontekstowe modele językowe oparte na architekturze Transformer [vaswani2017attention]. Model BERT (ang. *Bidirectional Encoder Representations from Transformers*) [devlin2019bert] generuje reprezentacje słów uwzględniające dwukierunkowy kontekst całego zdania, co pozwala na rozróżnienie znaczeń polisemicznych. Adaptacja modelu BERT do zadania generowania embeddingów zdaniowych zaowocowała powstaniem architektury Sentence-BERT [reimers2019sentence], umożliwiającej efektywne porównywanie podobieństwa semantycznego całych sekwencji tekstowych.

Współczesne badania zmierzają w kierunku multimodalnych przestrzeni embeddingowych, łączących reprezentacje różnych typów danych. Model CLIP [radford2021learning] tworzy wspólną przestrzeń wektorową dla tekstu i obrazów, umożliwiając wyszukiwanie obrazów na podstawie zapytań tekstowych i odwrotnie. Podobne podejście reprezentują modele takie jak ALIGN [jia2021scaling] czy współczesne architektury embeddingowe, takie jak Jina Embeddings [gunther2023jina], oferujące zunifikowaną przestrzeń dla wielu modalności i języków.

Embedding definiowany jest formalnie jako funkcja $f : \mathcal{X} \rightarrow \mathbb{R}^d$, która mapuje obiekty ze zbioru wejściowego $\mathcal{X}$ (słowa, zdania, dokumenty, obrazy) do d -wymiarowej przestrzeni wektorowej, przy czym podobieństwo semantyczne obiektów jest zachowane jako bliskość

geometryczna ich reprezentacji wektorowych. Miarą podobieństwa najczęściej stosowaną w praktyce jest podobieństwo kosinusowe:

$$\text{sim}(\mathbf{u}, \mathbf{v}) = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} \quad (1)$$

gdzie $\mathbf{u}$ i $\mathbf{v}$ są wektorami embeddingów porównywanych obiektów.

2.1.3 Architektura RAG

Duże modele językowe (ang. *Large Language Models*, LLM), takie jak GPT [brown2020language] czy LLaMA [touvron2023llama], pomimo imponujących zdolności generacyjnych, charakteryzują się istotnymi ograniczeniami w kontekście zastosowań specjalistycznych. Wiedza tych modeli jest zamrożona w momencie zakończenia treningu, co uniemożliwia uwzględnienie informacji aktualnych lub wysoce specjalistycznych. Ponadto modele te są podatne na zjawisko halucynacji - generowania treści brzmiących wiarygodnie, lecz niezgodnych z faktami [ji2023survey].

Architektura RAG (ang. *Retrieval-Augmented Generation*) [lewis2020retrieval] stanowi rozwiązanie tych problemów poprzez integrację komponentu wyszukiwania informacji z modelem generacyjnym. System RAG składa się z trzech głównych faz: indeksowania, wyszukiwania oraz generacji.

W fazie indeksowania dokumenty źródłowe są przetwarzane i dzielone na fragmenty (ang. *chunks*) o określonej długości. Każdy fragment jest następnie przekształcany przez model embeddingowy w reprezentację wektorową i zapisywany w wektorowej bazie danych wraz z metadanymi umożliwiającymi identyfikację źródła [johnson2019billion].

Faza wyszukiwania inicjowana jest przez zapytanie użytkownika, które jest transformowane do tej samej przestrzeni wektorowej co zindeksowane dokumenty. Na podstawie miary podobieństwa (typowo podobieństwa kosinusowego lub odległości euklidesowej) system identyfikuje k najbardziej podobnych fragmentów dokumentów.

W fazie generacji model językowy otrzymuje kontekst składający się z wyszukanych fragmentów dokumentów oraz oryginalnego zapytania użytkownika. Na tej podstawie generuje odpowiedź, która może być weryfikowana przez użytkownika poprzez porównanie z dostarczonymi źródłami.

Architektura RAG oferuje szereg zalet w kontekście zastosowań specjalistycznych. Po pierwsze, umożliwia aktualizację bazy wiedzy bez konieczności ponownego trenowania modelu językowego - wystarczy dodanie nowych dokumentów do indeksu wektorowego. Po drugie, zapewnia wyjaśnialność poprzez możliwość wskazania konkretnych fragmentów dokumentów wykorzystanych do wygenerowania odpowiedzi. Po trzecie, redukuje ryzyko halucynacji poprzez zakotwiczenie generowanej treści w dostarczonym kontekście [shuster2021retrieval].

TODO: tu diagram

2.2 Modele automatycznego rozpoznawania mowy

2.2.1 Historia i rozwój modeli ASR

Automatyczne rozpoznawanie mowy (ang. *Automatic Speech Recognition*, ASR) stanowi jedno z klasycznych zagadnień przetwarzania języka naturalnego, którego historia sięga lat siedemdziesiątych XX wieku. Wczesne systemy ASR opierały się na ukrytych modelach Markowa (ang. *Hidden Markov Models*, HMM), które modelowały sygnał mowy jako sekwencję dyskretnych stanów akustycznych [rabiner1989tutorial]. W podejściu tym zakłada się, że

obserwowany sygnał akustyczny jest generowany przez ukryty proces stochastyczny, którego stany odpowiadają jednostkom fonetycznym.

Rozszerzeniem modeli HMM były systemy hybrydowe GMM-HMM, łączące ukryte modele Markowa z mieszanymi gaussowskimi (ang. *Gaussian Mixture Models*) [gales2008application]. Mieszanki gaussowskie służyły do modelowania rozkładu prawdopodobieństwa emisji w poszczególnych stanach HMM, co pozwalało na lepsze uchwycenie zmienności akustycznej sygnału mowy. Systemy te wymagały jednak znacznej wiedzy eksperckiej. Konieczne było ręczne projektowanie cech akustycznych (np. współczynników MFCC), tworzenie słowników wymowy oraz definiowanie modeli fonologicznych dla danego języka.

Przełom w dziedzinie ASR nastąpił wraz z zastosowaniem głębokich sieci neuronowych. Początkowo sieci te zastępowały komponent GMM w systemach hybrydowych DNN-HMM [hinton2012deep], zachowując strukturę modelowania sekwencji opartą na HMM. Wprowadzenie mechanizmu uwagi (ang. *attention mechanism*) [bahdanau2014neural] oraz architektur typu sekwencja-do-sekwencji (ang. *sequence-to-sequence*) [sutskever2014sequence] umożliwiło bezpośrednie modelowanie zależności między sekwencją akustyczną a sekwencją tekstową bez konieczności jawnego definiowania wyrównania czasowego.

Architektura Transformer [vaswani2017attention], oparta wyłącznie na mechanizmie uwagi bez komponentów rekurencyjnych, znalazła szerokie zastosowanie w modelach ASR nowej generacji. Modele te, określane jako end-to-end, eliminują tradycyjny pipeline przetwarzania składający się z oddzielnych modułów akustycznego, leksykalnego i językowego. Zamiast tego realizują bezpośrednie mapowanie surowego sygnału audio na sekwencję tekstową, co upraszcza architekturę systemu i eliminuje propagację błędów między modułami.

2.2.2 Architektura współczesnych modeli ASR

Współczesne modele ASR można podzielić na dwie główne kategorie ze względu na metodę treningu: modele wykorzystujące uczenie samonadzorowane (ang. *self-supervised learning*) oraz modele trenowane w sposób nadzorowany (ang. *supervised learning*) na dużych zbiorach transkrybowanych nagrań.

Wav2Vec 2.0

Model Wav2Vec 2.0 [baevski2020wav2vec] reprezentuje podejście oparte na uczeniu samonadzorowanym. Architektura składa się z trzech głównych komponentów: enkodera konwolucyjnego (ang. *Convolutional Neural Network*, CNN), transformera oraz modułu kwantyzacji. Enkoder konwolucyjny przetwarza surowy sygnał audio (próbkowany typowo z częstotliwością 16 kHz) i przekształca go w sekwencję wektorów cech o niższej rozdzielczości czasowej. Następnie transformer przetwarza tę sekwencję, generując kontekstowe reprezentacje uwzględniające zależności długozasięgowe.

Proces uczenia samonadzorowanego w modelu Wav2Vec 2.0 opiera się na maskowaniu fragmentów sekwencji wejściowej oraz uczeniu kontrastowym (ang. *contrastive learning*). Model jest trenowany do identyfikacji prawidłowych kwantyzowanych reprezentacji zamaskowanych segmentów spośród zbioru negatywnych przykładów. Podejście to pozwala na wykorzystanie ogromnych ilości nieetykietowanych nagrań audio do uczenia semantycznie bogatych reprezentacji akustycznych, bez konieczności korzystania z dużych ilości transkrybowanych nagrań.

Adaptacja modelu do zadania transkrypcji wymaga etapu dostrajania (ang. *fine-tuning*) z wykorzystaniem stosunkowo niewielkiego zbioru danych etykietowanych. Eksperymenty wykazały, że model Wav2Vec 2.0 osiąga konkurencyjne wyniki przy użyciu zaledwie

kilkudziesięciu minut transkrybowanych nagrań [baevski2020wav2vec]. Stanowi to istotną zaletę w kontekście języków i domen o ograniczonych zasobach etykietowanych. Dzięki temu podejściu Wav2Vec 2.0 znacząco zredukował zapotrzebowanie na dane z etykietami, jednocześnie poprawiając jakość rozpoznawania mowy w warunkach szumu, zmienności mówców i zróżnicowanego otoczenia akustycznego.

TODO: tu diagram

HuBERT

Model HuBERT (ang. *Hidden-Unit BERT*) [hsu2021hubert] stanowi rozwinięcie koncepcji uczenia samonadzorowanego dla reprezentacji mowy. Podobnie jak Wav2Vec 2.0, HuBERT wykorzystuje architekturę składającą się z enkodera konwolucyjnego oraz transformera. Zasadnicza różnica dotyczy jednak metody uczenia.

W modelu Wav2Vec 2.0 uczenie opiera się na zadaniu kontrastywnym, w którym model rozróżnia prawdziwe reprezentacje zamaskowanych segmentów od negatywnych przykładów. HuBERT natomiast wykorzystuje podejście inspirowane modelem BERT [devlin2019bert] z dziedziny przetwarzania języka naturalnego. Model jest trenowany do przewidywania dyskretnych pseudoetykiet przypisanych zamaskowanym fragmentom sygnału audio.

Pseudoetykiety generowane są w procesie iteracyjnym. W pierwszej iteracji stosuje się algorytm k-średnich (ang. *k-means clustering*) do cech MFCC surowego sygnału audio, uzyskując początkowy zbiór klastrów. Model HuBERT jest następnie trenowany do przewidywania przypisań klastrowych dla zamaskowanych segmentów. W kolejnych iteracjach pseudoetykiety są aktualizowane poprzez zastosowanie algorytmu k-średnich do reprezentacji cech ukrytych wytrenowanego modelu, co prowadzi do coraz bardziej semantycznych grupowań.

Zaletą tego podejścia jest możliwość uczenia bez konieczności definiowania negatywnych przykładów, co upraszcza proces treningowy. Ponadto iteracyjne doskonalenie pseudoetykiet pozwala modelowi na stopniowe odkrywanie struktury językowej sygnału mowy. Eksperymenty wykazały, że HuBERT osiąga wyniki porównywalne lub lepsze od Wav2Vec 2.0 w zadaniach rozpoznawania mowy, szczególnie w scenariuszach z ograniczoną ilością danych etykietowanych [hsu2021hubert].

Wariantem modelu HuBERT jest mHuBERT, przystosowany do przetwarzania wielojęzycznego, co rozszerza zastosowania oryginalnego modelu na języki o ograniczonych zasobach.

TODO: tu diagram

Whisper

Model Whisper [whisper] reprezentuje odmienne podejście, oparte na uczeniu nadzorowanym w dużej skali. Model został wytrenowany na zbiorze 680 tysięcy godzin transkrybowanych nagrań audio pozyskanych z internetu, obejmujących 99 języków. Architektura Whisper składa się z enkodera i dekodera, oba oparte na transformerze.

W przeciwieństwie do modelu Wav2Vec 2.0, Whisper operuje na melspektrogramach. Stanowią one reprezentację częstotliwościową sygnału audio uwzględniającą charakterystykę ludzkiego słuchu. Takie podejście umożliwia normalizację dynamiki i redukcję szumu na etapie ekstrakcji cech, a jednocześnie przenosi ciężar modelowania z niskopoziomowych cech akustycznych na wyższe zależności językowe i kontekstowe. Enkoder przetwarza melspektrogram i generuje sekwencję reprezentacji ukrytych. Dekoder, działający w sposób

autoregresyjny, generuje kolejne tokeny tekstu na podstawie reprezentacji z enkodera oraz wcześniej wygenerowanych tokenów.

Istotną cechą modelu Whisper jest uczenie wielozadaniowe (ang. *multitask learning*). Model jest trenowany równocześnie do realizacji kilku zadań: transkrypcji mowy, detekcji języka, znaczników czasowych oraz tłumaczenia mowy na język angielski. Zadanie jest specyfikowane poprzez specjalne tokeny kontrolne umieszczane na początku sekwencji wyjściowej.

Zaletą modelu Whisper jest gotowość do użycia bez konieczności dostrajania (ang. *zero-shot*). Dzięki treningowi na zróżnicowanym zbiorze danych model wykazuje odporność na szum, różne warunki akustyczne oraz akcenty. Wielojęzyczność modelu pozwala na transkrypcję nagrań w wielu językach, w tym w języku polskim, bez dodatkowej adaptacji.

TODO: tu diagram

Data2Vec

Model Data2Vec [**data2vec**] stanowi uogólnienie podejść do uczenia samonadzorowanego, oferując zunifikowaną architekturę zdolną do przetwarzania różnych modalności: mowy, obrazów oraz tekstu. Kluczową innowacją jest rezygnacja z przewidywania celów specyficznych dla modalności na rzecz predykcji kontekstowych reprezentacji latentnych.

Architektura Data2Vec opiera się na mechanizmie samodestylacji z wykorzystaniem modelu nauczyciela (ang. *teacher*) oraz ucznia (ang. *student*). Model nauczyciela przetwarza pełne dane wejściowe i generuje reprezentacje latentne. Model ucznia, otrzymując zamaskowane dane, przewiduje reprezentacje wygenerowane przez nauczyciela dla zamaskowanych fragmentów. Wagi nauczyciela są aktualizowane jako wykładnicza średnia krocząca (EMA) wag ucznia, co zapewnia stabilność procesu uczenia.

W przypadku mowy Data2Vec wykorzystuje architekturę transformera analogiczną do Wav2Vec 2.0. Eksperymenty na zbiorze LibriSpeech wykazały, że model osiąga niższy wskaźnik WER niż Wav2Vec 2.0 i HuBERT, szczególnie przy ograniczonej ilości danych etykietowanych [**data2vec**]. Zunifikowane podejście do uczenia upraszcza rozwój modeli multimodalnych i umożliwia transfer wiedzy między modalnościami.

TODO: tu diagram

2.2.3 Adaptacja do domeny specjalistycznej

Pomimo wysokiej jakości modeli ogólnego przeznaczenia, zastosowania w domenach specjalistycznych wymagają często dodatkowej adaptacji. Terminologia medyczna, prawnicza czy techniczna jest słabo reprezentowana w ogólnych zbiorach treningowych, co prowadzi do błędów rozpoznawania specjalistycznych terminów.

Przykładem takiej adaptacji jest projekt ADMEDVoice [**ADMEDVoice**], w ramach którego przeprowadzono dostrajanie modelu Whisper Medium do transkrypcji polskiej mowy medycznej. Zbiór treningowy obejmował nagrania 28 mówców w różnych scenariuszach akustycznych, zawierające terminologię kliniczną. Dostrajanie pozwoliło na redukcję wskaźnika błędu słów (ang. *Word Error Rate*, WER) z 24% do 9,5%, co stanowi znaczącą poprawę jakości transkrypcji w domenie medycznej.

Wyniki te ilustrują znaczenie danych domenowych dla jakości systemów ASR w zastosowaniach specjalistycznych. Jednocześnie wskazują na wyzwanie związane z ograniczoną dostępnością takich zbiorów, szczególnie dla języków innych niż angielski.

Analogiczny problem dotyczy modeli embeddingowych i językowych. Rozwiązaniem jest adaptacja modeli do konkretnych domen poprzez dodatkowy trening na specjalistycznych

korpusach. W dziedzinie przetwarzania języka naturalnego powstały modele takie jak BioBERT [lee2020biobert], pretrenowany na korpusach tekstów biomedycznych z PubMed, czy PubMedBERT [gu2021domain], trenowany od podstaw wyłącznie na tekstach z domeny biomedycznej. Modele te wykazują znacząco lepszą jakość w zadaniach związanych z tekstami medycznymi w porównaniu z modelami ogólnego przeznaczenia.

2.2.4 Porównanie podejść

Modele Wav2Vec 2.0, HuBERT oraz Whisper reprezentują różne podejścia do problemu ASR. Wav2Vec 2.0 i HuBERT wykorzystują uczenie samonadzorowane, co pozwala na efektywne wykorzystanie nieetykietowanych nagrań audio. Różnią się jednak metodą uczenia: Wav2Vec 2.0 stosuje uczenie kontrastywne, podczas gdy HuBERT opiera się na przewidywaniu pseudoetykiet w sposób analogiczny do modelu BERT. Whisper reprezentuje odmienne podejście, oferując wysoką jakość bez konieczności dostrajania dzięki treningowi nadzorowanemu na maszynym zbiorze danych.

Otwartym pytaniem pozostaje, czy reprezentacje ukryte generowane przez modele ASR zawierają informację semantyczną wykraczającą poza poziom akustyczny i fonetyczny. Zagadnienie to stanowi motywację dla badań nad bezpośrednim wykorzystaniem reprezentacji modeli ASR w zadaniach wyszukiwania informacji.

2.3 Wyjaśnialność modeli wykorzystujących uczenie głębokie

TODO: Semantyczność reprezentacji, historia, podejścia jakościowe oparte o rzadkie autoenkodery, ilościowe w ramach NLP i nie tylko.

2.4 Systemy wyszukiwania informacji w oparciu o sygnał audio

Rosnące zapotrzebowanie na interfejsy głosowe motywuje rozwój systemów wyszukiwania informacji zdolnych do przetwarzania zapytań audio. Tradycyjne podejście opiera się na architekturze kaskadowej: sygnał mowy jest najpierw transkrybowany przez system ASR, a następnie uzyskany tekst wykorzystywany jest w standardowym procesie wyszukiwania. Rozwiązanie to jest jednak podatne na propagację błędów rozpoznawania mowy, szczególnie w przypadku terminologii specjalistycznej, różnych akcentów lub nagrań niskiej jakości.

W odpowiedzi na te ograniczenia powstały dwa główne nurty badawcze. Pierwszy koncentruje się na architekturach end-to-end, które uczą się bezpośredniego mapowania sygnału audio na reprezentacje semantyczne, omijając etap transkrypcji. Drugi wykorzystuje podejścia multimodalne, tworzące wspólną przestrzeń reprezentacji dla danych audio, tekstowych i obrazu.

2.4.1 Podejścia end-to-end

SpeechDPR. Model SpeechDPR (ang. *Speech Dense Passage Retriever*) [lin2024speechdprendtoendspoken] stanowi pierwsze rozwiązanie typu end-to-end dla problemu wyszukiwania fragmentów mowy w zadaniach odpowiadania na pytania. Model uczy się semantycznych reprezentacji na poziomie zdaniowym poprzez destylację wiedzy z systemu kaskadowego składającego się z nienadzorowanego ASR oraz tekstowego retriever'a opartego na gęstych reprezentacjach. Proces ten nie wymaga ręcznie transkrybowanych danych mowy, co stanowi istotną zaletę w kontekście języków o ograniczonych zasobach.

SpeechRAG. SpeechRAG [min2025speechretrievalaugmentedgenerationautomatic] rozszerza architekturę RAG o bezpośrednie przetwarzanie audio. System składa się z retriever'a audio oraz generatora opartego na modelu języka mowy (SLM, ang. *Speech Language Model*). Kluczową innowacją jest dostrojenie pretrenowanego enkodera mowy do roli adaptera podłączonego do zamrożonego retriever'a tekstowego. Dzięki wyrównaniu przestrzeni embeddingów retriever audio może wyszukiwać fragmenty na podstawie zapytań tekstowych. W fazie generacji model SLM otrzymuje jako kontekst oryginalne fragmenty audio, eliminując straty informacyjne wynikające z konwersji mowa-tekst.

2.4.2 Podejścia multimodalne

Budowa systemów wyszukiwania opartych na wspólnej przestrzeni reprezentacji dla audio i tekstu jest ułatwiona dzięki modelom takim jak Data2Vec (opisany w sekcji 2.2), które oferują zunifikowane podejście do uczenia reprezentacji różnych modalności.

WavRAG. WavRAG [wavRAG] umożliwia reprezentowanie sygnałów audio w tej samej przestrzeni semantycznej co dane tekstowe. Pozwala to na pełną integrację informacji mówionej i pisanej w ramach jednego systemu. Zapytania głosowe są kodowane jako wektory w przestrzeni latentnej, a wyszukiwanie opiera się na bezpośrednim dopasowywaniu embeddingów akustycznych i tekstowych za pomocą podobieństwa kosinusowego.

Wyszukiwanie multimodalne dla ASR. Kolehmainen et al. [kolehmainen2024multimodalretrievallar] zbadali zastosowanie wyszukiwania multimodalnego do poprawy jakości rozpoznawania mowy. Zaproponowany system wykorzystuje dwie techniki: kNN-LM (ang. *k-Nearest Neighbors Language Model*) oraz mechanizmy cross-attention. Wyszukiwanie oparte na mowie prowadzi do redukcji WER o nawet 50% w porównaniu z bazowym modelem. System osiągnął wyniki state-of-the-art w zadaniu rozpoznawania mowy na zbiorze Spoken-Squad.

2.4.3 Charakterystyka i porównanie podejść

Przedstawione podejścia łączy dążenie do eliminacji lub ograniczenia roli tradycyjnego ASR jako pośredniego etapu przetwarzania. Zarówno architektury end-to-end, jak i multimodalne wykazują przewagę nad systemami kaskadowymi w warunkach niskiej jakości rozpoznawania mowy. Bezpośrednie uczenie reprezentacji semantycznych z sygnału audio przynosi dwie kluczowe korzyści: redukuje propagację błędów transkrypcji oraz zachowuje informacje prozodyczne i paralingwistyczne tracone w procesie konwersji mowa-tekst. Stanowi to fundamentalną zmianę paradygmatu w projektowaniu systemów wyszukiwania informacji opartych na danych mowy.

3 Semantyczne reprezentacje wektorów cech modeli ASR

3.1 Założenia teoretyczne

3.1.1 Semantyczne a syntaktyczne reprezentacje audio w wektorach cech

Dla proponowanego przez nas rozwiązania, potencjalnie najważniejszą charakterystyką, którą wykazują się dostępne modele ASR jest postać ukrytej (latentnej) reprezentacji enkodowanej przez nie na podstawie danych wejściowych. Potencjalnie, większa wierność semantycznemu znaczeniu wypowiedzianego zdania doprowadzi do dokładniejszej translacji wyjścia enkodera na współdzieloną przestrzeń embeddingów, czego konsekwencją będą lepsze osiągi systemu wyszukiwania dla użytkownika końcowego.

3.1.2 Wpływ charakterystyki wektorów cech na jakość embeddingów w modelach wielojęzycznych

Kolejnym aspektem ewaluowanym przez nas w ramach eksperymentu są podobieństwa wyników modeli dla zdań o tym samym znaczeniu w kilku językach. Dla modeli enkodujących semantykę danych, reprezentacje dla dwóch znaczeniowo identycznych zdań w dwóch różnych językach powinny być do siebie podobne według przyjętej metryki podobieństwa. Przykładowo, miara podobieństwa dla reprezentacji latentnych dla zdań "Kocham zwiedzać włoskie miasta" i "I love sightseeing Italian cities", dla modelu semantycznego, powinna mieć jak największą wartość.

Należy mieć na uwadze, że różnice w historii języka, jego strukturze i alfabecie istotnie wpływają na otrzymane wyniki podobieństwa dla takich zdań. Zróżnicowanie to zostało zbadane przez Aleshinę et. al w ich pracy ewaluującej rozkłady embeddingów zdań dla dziesięciu różnych języków [**multilanguageEmbeddingDifferences**]. Korzystając z modelu MUSE [**museModel**] operującego na pojedynczych słowach, wykazali oni znaczące pokrycie klastrów embeddingów dla języków o podobnej historii (arabski i hiszpański) jak i o podobnie prostej morfologii i częściowo współdzielonym słownictwie (angielski, chiński, indonezyjski), i izolację klastrów dla wybranych języków (rosyjski, o innym alfabecie i bardziej skomplikowanej morfologii w świetle infleksji języka). Najbardziej interesującym dla nas wnioskiem są podobieństwa dla słów zapożyczonych z innych języków – wiele terminów medycznych wywodzi się z języka łacińskiego, co oznacza potencjalnie wysokie podobieństwo dla takich zwrotów w języku angielskim i polskim, jak i w innych językach [**latinMedical**].

Wysoka miara podobieństwa dla modelu ASR ewaluowanego dla danych wielojęzycznych oznaczałaby nie tylko dobre radzenie sobie z samą semantyką wypowiedzianych zdań, lecz także potencjalnie wysoki potencjał do przeprowadzenia treningu modelu na specjalistycznych danych dostępnych w innych językach. Model wykazujący się taką cechą byłby niezwykle cenny dla poprawienia jakości wyszukiwania informacji dla nie tylko polskojęzycznych, ale również innych języków wspieranych przez ten model. Właśnie taki proces destylacji wiedzy zbadali w swojej pracy Piperno et. al [**multilingualDomainTranslation**], z powodzeniem korzystając z anglojęzycznych zbiorów słownictwa o tematyce medycznej do poprawienia osiągnięć modeli dla danych w językach hiszpańskim, niemieckim i francuskim. Przeprowadzony w ten sposób dodatkowy trening pozwoliłaby nam na znaczące polepszenie naszego całościowego rozwiązania, umożliwiając skorzystanie z większej ilości danych dostępnych w języku angielskim i przełożenia zdobytej przez model wiedzy na język polski dla zbioru ADMEDVoice [**ADMEDVoice**].

3.2 Metodologia

3.2.1 Ocena jakości embeddingów

W celu rzetelnej weryfikacji powyższej hipotezy dotyczącej semantyki w reprezentacjach latentnych modeli ASR, sformułowaliśmy eksperyment wykorzystujący istniejące modele embeddingowe dla tekstu wspierające wiele języków. Wykorzystując istniejące zbiory danych zawierające zarówno audio wypowiedzianego zdania, jak i jego transkrypcję, za ich pomocą wygenerowaliśmy przykłady treningowe dla każdego zdania inspirowane metodą *triplet loss* [tripletLoss].

$$\mathcal{L}_{\text{triplet}} = \max \left(0, \|f(x^a) - f(x^p)\|_2^2 - \|f(x^a) - f(x^n)\|_2^2 + \alpha \right) \quad (2)$$

Na początku dla transkrypcji każdego zdania w zbiorze danych wygenerowaliśmy jego embeddingi za pomocą każdego z ewaluowanych modeli embeddingowych. Następnie, dla każdego zdania (oznaczonego jako x^a – *anchor*), wyliczyliśmy dystans (norma L2) do każdego z pozostałych zdań dla każdego modelu embeddingowego:

$$D(x_{emb}^a, x_{emb}) = \|x_{emb}^a - x_{emb}\|_2^2 = \sqrt{(x_{emb}^a - x_{emb})^2} \quad (3)$$

Następnie, na podstawie wygenerowanych w ten sposób zbiorów odległości, wybraliśmy losowo przykłady pozytywne x^p i negatywne x^n . Przykłady pozytywne stanowiły losowe zdanie spośród najbliższych (najbardziej podobnych) dziesięciu przykładów, z kolei przykłady negatywne spośród najmniej podobnych czterdziestu procent zdań. Losowość miała na celu zapewnić stosunkowo równomierny rozkład przykładów negatywnych spośród całego zbioru danych.

Posiadając trzy przykłady x^a , x^n i x^p dla każdego unikalnego zdania w zbiorze, następnym krokiem było wygenerowanie embeddingów dla każdego z ewaluowanych modeli ASR. Następnie, porównywaliśmy je za pomocą metryki $m(x_1, x_2)$, otrzymując w rezultacie ewaluację relatywnego podobieństwa między x^a i kolejno x^p i x^n :

$$S(x_{emb,asr}) = m(x_{emb,asr}^a, x_{emb,asr}^n) - m(x_{emb,asr}^a, x_{emb,asr}^p) \quad (4)$$

Metryka, którą wykorzystaliśmy podczas tej ewaluacji to *Maximum Mean Discrepancy* (MMD) [mmd]. Jest ona przeznaczona do porównywania różnicy między dwoma dwuwymiarowymi tensorami, które stanowią w naszym przypadku embeddingi wygenerowane przez modele ASR. Jest ona wyrażana wzorem:

$$\widehat{\text{MMD}}^2(X, Y) = \frac{1}{m^2} \sum_{i=1}^m \sum_{i'=1}^m k(x_i, x_{i'}) + \frac{1}{n^2} \sum_{j=1}^n \sum_{j'=1}^n k(y_j, y_{j'}) - \frac{2}{mn} \sum_{i=1}^m \sum_{j=1}^n k(x_i, y_j) \quad (5)$$

Z racji określania różnicy zamiast podobieństwa między dwoma reprezentacjami, w ramach porównania opisanego równaniem 4, wartość ewaluacji $S(x_{emb,asr})$ będzie dodatnia, jeśli model poprawnie uchwycił relatywne podobieństwa semantyczne przykładów x^a , x^n i x^p . W ten sposób możliwe jest ilościowe podejście do ewaluacji jakości w semantyczności reprezentacji modelu w ramach danego zbioru danych.

Ponadto, w celu zbadania rozkładu wartości ewaluacji $S(x_{emb,asr})$, dla zagregowanych w ramach modeli embeddingowych wyników dopasowaliśmy rozkład Student-t, dla którego funkcja gęstości prawdopodobieństwa jest wyrażana wzorem:

$$f(t; \nu, \mu, \sigma) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right) \sqrt{\nu\pi} \sigma} \left[1 + \frac{1}{\nu} \left(\frac{t - \mu}{\sigma}\right)^2\right]^{-\frac{\nu+1}{2}} \quad (6)$$

Pozwala on na analizę statystyczną zachowania modeli w ramach naszego podejścia ilościowego, dostarczając informacji na temat stabilności i zdolności modelu do separacji przykładów pozytywnych i negatywnych, które są niezwykle cennymi czynnikami przy doborze właściwego modelu do dalszych eksperymentów.

3.2.2 Analiza rozkładu embeddingów w przestrzeni

Kolejnym krokiem analizy ilościowej jakości embeddingów generowanych przez modele ASR jest zbadanie obecności "efektu stożka (cone effect)", opisanego w pracy *Mind the Gap: Understanding the Modality Gap in Multi-modal Contrastive Representation Learning* [liang2022mind]. Oryginalna praca skupia się na metodach badania różnicy w reprezentacji danych o różnej modalności w modelach embeddingowych. Głównym narzędziem proponowanym przez autorów jest badanie podobieństwa kosinusowego między embeddingami dla każdej z obsługiwanej przez model modalności. Niech $x^{(i)}$ oznacza dane wejściowe dla modalności i , f_i model dla modalności i , z^i znormalizowany embedding dla modalności i i $s(x^{(i)}, x^{(j)})$ podobieństwo kosinusowe dla porównywanych modalności i i j , wtedy:

$$z^{(1)} = \frac{f_1(x^{(1)})}{\|f_I(x^{(1)})\|_2}, \quad z^{(2)} = \frac{f_2(x^{(2)})}{\|f_T(x^{(2)})\|_2}, \quad s(x^{(1)}, x^{(2)}) = \langle z^{(1)}, z^{(2)} \rangle \quad (7)$$

Wyliczenia te pozwalają na zbadanie właściwości n -wymiarowego stożka, w którym znajdują się embeddingi wygenerowane przez model. Różnice między podobieństwem wewnątrz modalności a podobieństwem inter-modalnym pozwalają na analizę różnicy, według której model reaguje na różne rodzaje danych wejściowych.

Analiza ta nie jest przydatna tylko dla proponowanych przez nas modeli z rodziny speech-to-retrieval. W pracy *The Geometry of Multilingual Language Model Representations*, autorzy badali również podobieństwo między reprezentacjami danych dla różnych języków obsługiwanych przez model językowy XLM-R [chang2022geometry]. Rezultaty przedstawione przez autorów udowodniły, że podprzestrzenie zajmowane przez embeddingi poszczególnych języków są podobne do siebie, lecz przesunięte w hiperprzestrzeni.

Mając na uwadze obie te prace, jak i cel naszej analizy, postanowiliśmy połączyć oba podejścia. Poprzez traktowanie języków jako modalności w świetle efektu stożka i mając na uwadze potencjalne przesunięcia podprzestrzeni dla różnych języków w ramach dziedziny przetwarzania tekstu, zbadana została umiejętność kodowania znaczenia semantycznego mowy przez modele ASR w ramach przetwarzania danych wielojęzycznych.

W celu bardziej kompleksowego wpływu, jaki ma język danych na końcowy rozkład embeddingów modelu, zastosowaliśmy również zabieg wybielania (*whitening*), zaadaptowany z pracy *Concept whitening for interpretable image recognition* [whitening]. W tej pracy autorzy zaproponowali metodę wybielania w modelach, mającą zastąpić warstwę *Batch Normalization*. Jest to metoda wymuszenia takiej struktury przestrzeni latentnej modelu, aby wektory jednostkowe w przestrzeni ukrytej stanowiły reprezentację pewnego konceptu, który stanowi część dodatkowego zbioru treningowego wykorzystanego przy uczeniu takiego modelu. O ile oryginalne zastosowanie wybielania odbywa się w trakcie samego treningu, w pracy *WhiteningBERT: An Easy Unsupervised Sentence Embedding Approach*, wykorzystana ona została do poprawy jakości embeddingów tekstowych z modeli z rodziny BERT [whiteningbert]. Poprzez dekorrelację wynikowej przestrzeni reprezentacji danych

wejściowych za pomocą wybielania, jakość wyszukiwania informacji zdecydowanie wzrosła. Nasza adaptacja tej metody polega na samej ewaluacji końcowej przestrzeni embeddingowej za pomocą ewaluacji efektu stożka po przeprowadzeniu zabiegu wybielania. Pozwoli to na zbadanie, czy dany model ASR traktuje różne języki jako swoiste "koncepty", co oznaczałoby rozdzielanie reprezentacji danych na poszczególne języki w wybielonej już przestrzeni i potencjalne trudności z transferem wiedzy pozyskanej ze zbiorów specjalistycznych w języku angielskim na taką wiedzę w języku polskim.

Wybielenie wynikowej przestrzeni embeddingowej modelu ASR wyrażane jest następującym wzorem 8:

$$\begin{aligned}\mu &= \frac{1}{N} \sum_{i=1}^N E_i, \\ U\Lambda U^\top &= \frac{1}{N-1} (E - \mu)^\top (E - \mu), \\ E_{\text{wyb}} &= (E - \mu) U (\Lambda + \varepsilon I)^{-1/2}.\end{aligned}\tag{8}$$

gdzie $E \in \mathbb{R}^{N \times d}$ oznacza macierz embeddingów z N próbkami o wymiarze d , a $\mu \in \mathbb{R}^d$ jest średnią embeddingów po pooling-u na podstawie średniej. Macierz kowariancji $\frac{1}{N-1} (E - \mu)^\top (E - \mu)$ jest poddawana dekompozycji do postaci $U\Lambda U^\top$, gdzie U zawiera wektory własne (*eigenvectors*), a Λ odpowiadające im wartości własne (*eigenvalues*) (posortowane malejąco). Wybielone embeddingi E_{wyb} otrzymywane poprzez centrowanie, rotację oraz skalowanie każdej składowej głównej przez $(\lambda_i + \varepsilon)^{-1/2}$, gdzie $\varepsilon > 0$ zapewnia stabilność numeryczną (w naszych eksperymentach $\varepsilon = 10^{-5}$).

Kolejną transformacją, w świetle której zbadaliśmy powyższe zjawisko, jest przekształcenie *All But the Top* [**abtt**], które również używane jest w celu poprawienia końcowej jakości embeddingów generowanych przez modele. Polega ono na zgromadzeniu embeddingów wokół początku układu współrzędnych, usunięcia pierwszego komponentu na podstawie analizy PCA i normalizacji L2. ABTT pozwala na sprawdzenie, czy informacje o języku mają wpływ na rozkład danych w przestrzeni embeddingowej, podobnie jak w przypadku wybielania. Może być ono jednak interpretowane jako mniej destruktywne dla oryginalnego rozkładu embeddingów, ponieważ nie dekoreluje ono danych.

Proces transformacji danych metodą ABTT wyrażany jest wzorem 9:

$$\begin{aligned}\mu &= \frac{1}{N} \sum_{i=1}^N X_i, & X_c &= X - \mu, \\ X_c &= USV^\top, & v_1 &= V_{:,1}, \\ X_{\text{abtt}} &= \frac{(I - v_1 v_1^\top) X_c}{\|(I - v_1 v_1^\top) X_c\|_2 + \varepsilon}\end{aligned}\tag{9}$$

gdzie $X \in \mathbb{R}^{N \times d}$ oznacza macierz embeddingów po pooling-u na podstawie średniej, a $X_i \in \mathbb{R}^d$ jej i -ty wiersz. Wektor $\mu \in \mathbb{R}^d$ jest empiryczną średnią tych embeddingów, a X_c oznacza dane wycentrowane. Rozkład SVD $X_c = USV^\top$ definiuje główne składowe danych, gdzie $v_1 = V_{:,1}$ jest pierwszą składową główną. Ostateczna reprezentacja X_{abtt} powstaje poprzez projekcję na ortogonalne do v_1 podprzestrzeń oraz normalizację L2 z małym składnikiem stabilizującym $\varepsilon > 0$ (w naszych eksperymentach $\varepsilon = 10^{-5}$).

3.2.3 Analiza wpływu przetwarzania embeddingów na zachowanie semantyki

Mając na uwadze dwa powyższe eksperymenty, ostatnią z proponowanych metod ewaluacji przestrzeni embeddingowej modeli ASR pod kątem semantyki jest połączenie obu ewaluacji. Embeddingi po procesie wybielania lub ABTT poddane zostały identycznej ewaluacji ilościowej z wykorzystaniem przykładów x^a , x^n i x^p . Tym razem, zamiast metryki MMD 5, zbadane zostało podobieństwo kosinusowe w ramach tych trzech przykładów, w celu uzyskania metryki poprawnej klasyfikacji C , która opisana jest równaniem 10:

$$s(x^{(1)}, x^{(2)}) = \frac{\langle x^{(1)}, x^{(2)} \rangle}{\|x^{(1)}\|_2 \|x^{(2)}\|_2}, \quad (10)$$
$$C = s(x^a, x^p) - s(x^a, x^n).$$

Naturalnie, równanie to określa pewne sformułowanie używanego w treningu modeli embeddingowych *triplet loss*. Jednakże, brak kontroli dokładnego doboru przykładów x^p i x^n sprawia, że dokładna wartość metryki C nie wnosi wiele wartości do analizy działania modelu. Naturalnie, w przypadku zbliżonego znaczenia semantycznego tych dwóch przykładów, miałyby ona wartość bliską zeru, dla przykładów nie powiązanych ze sobą – pewną wartość pozytywną z przedziału $\langle 0, 2 \rangle$. Jednakże, całościowa analiza liczby przykładów, w ramach których $C > 0$ pozwoli na wystarczająco dobrą analizę zachowania modeli ASR po wybielaniu lub procesie ABTT.

3.2.4 Ewaluowane modele ASR

W ramach kompleksowej ewaluacji różnych modeli ASR wybraliśmy cztery dostępne modele stanowiące state-of-the-art w ramach dziedziny transkrypcji audio. Modele te trenowane były w celu maksymalizacji dokładności transkrypcji, bez narzuconych ograniczeń dotyczącym maksymalizacji podobieństwa między reprezentacjami dla semantycznie podobnego sygnału audio, lecz ich osiągi dla transkrypcji dla wielu języków wskazują na częściowo semantyczne osadzenie ich reprezentacji.

Pierwszym z nich jest Whisper autorstwa OpenAI, wspierający ponad 90 języków [whisper]. Jak wykazały badania Rao et. al [whisperSemanticAlign], wykazuje się on stosunkową łatwością do przekształcenia jego reprezentacji do reprezentacji semantycznej, co jest częściowym celem naszego systemu. Ponadto, został on wykorzystany z powodzeniem do ASR na zbiorze ADMEDVoice [ADMEDVoice], co wykazuje jego zdolność do radzenia sobie na specjalistycznych danych medycznych w języku polskim po odpowiednim dotrenowaniu.

Kolejnymi dwoma modelami są modele z rodziny Wav2Vec autorstwa Mety - Wav2Vec 2.0 [baevski2020wav2vec] i Data2Vec [data2vec]. Modele te korzystają z tej samej architektury, lecz różnią się znacząco w ramach metody ich trenowania. Oba modele korzystają z predykcji maskowanej reprezentacji audio inspirowanej treningiem modelu BERT [devlin2019bert]. Data2Vec opiera się na treningu teacher-student, w którym modelowi *student* podawana jest zamaskowana reprezentacja enkodera współdzielonego z modelem *teacher*, który dokonuje predykcji na pełnych danych. Celem treningu jest minimalizacja różnicy między tymi dwoma reprezentacjami. Wav2Vec 2.0 operuje z kolei na tylko jednym modelu, który dokonuje predykcji zarówno na danych zamaskowanych i pełnych. Należy nadmienić, że nie wspierają one w swojej bazowej formie języków poza angielskim, co nie wyklucza ich wykorzystania po odpowiednim dotrenowaniu.

Ostatnim z ewaluowanych modeli jest HuBERT autorstwa Mety [hsu2021hubert]. Trenowany jest on na podstawie predykcji klas, oznaczonych jako identyfikator klastra wynikającego

z klasteryzacji za pomocą algorytmu k-means cech ekstrapolowanych z sygnału audio za pomocą modelu Wav2Vec 2.0, stanowiąc swoiste ulepszenie metody Wav2Vec 2.0. Sam HuBERT nie wspiera języków poza językiem angielskim, lecz pokrewne modele z rodziny mHuBERT oferują wsparcie dla wielu innych języków, stąd też do ewaluacji tej architektury skorzystaliśmy z modelu mHuBERT-147 [mhubert].

3.2.5 Ewaluowane modele embeddingowe

W celu przeprowadzenia rzetelnej analizy możliwości modeli ASR w świetle enkodowania informacji semantycznych, do naszych eksperymentów wykorzystaliśmy trzy różne modele embeddingowe.

Pierwszym z nich był model LaBSE autorstwa Google Research [feng-et al-2022-language]. Jest to model embeddingowy, którego celem jest jednolita reprezentacja danych wejściowych w jednej przestrzeni, bez względu na ich język. Jest on oparty na architekturze transformer inspirowanej modelem BERT i produkuje embeddingi o jednolitej długości dla różnych zdań. Podczas treningu, zdania o tej samej semantyce, lecz w różnych językach, osadzone były w przestrzeni jak najbliżej siebie. W ten sposób model osiąga bardzo dobre wyniki w wyszukiwaniu informacji w różnych językach (metryka accuracy rzędu 95% na zbiorze Tatoeba [tiedemann-2020-tatoeba]).


Drugim z wykorzystywanych modeli był model Clip autorstwa OpenAI [radford2021clip]. Jest to model multimodalny, pozwalający na osadzanie zarówno tekstu, jak i obrazu, w jednej przestrzeni. Pozwala to na wyszukiwanie m.in. obrazu na podstawie tekstu. Przez charakterystykę danych treningowych, czyli obrazy i ich opisy w języku naturalnym, jest stworzony do radzenia sobie z danymi o charakterze opisowym. Jednakże, brak wsparcia dla języków poza językiem angielskim stanowi istotne ograniczenie do części naszych eksperymentów.

Ostatnim z modeli jest model Jinav4, autorstwa JinaAI [jina_v4]. Jest to model zarówno multimodalny (zdjęcia i tekst), jak i wspierający ponad 30 języków. Jest on nastawiony na jakość wyszukiwania informacji i jego wykorzystanie w przetwarzaniu w ramach architektury RAG [lewis2020retrieval]. W ramach jego treningu wykorzystano metodologię hard negative mining [robinson2021contrastive], pozwalającą na kontrolę geometrii między próbką bazową a przykładem negatywnym, co przyczyniło się do redukcji efektu stożka między modalnościami obsługiwanymi przez model. Konsekwencją tego zjawiska jest większa stabilność wyszukiwania i większa separacja danych w świetle podobieństwa kosinusowego.

3.3 Eksperymenty

3.3.1 Założenia projektowe

W ramach eksperymentu poddaliśmy ewaluacji działanie powyższych modeli dla dwóch zbiorów danych. Pierwszym z nich był anglojęzyczny zbiór danych *Medical Speech, Transcription, and Intent* [generalMedicalDataset]. Zawiera on 8,5 godzin audio wraz z transkrypcjami dotyczącymi powszechnych objawów chorób, takich jak gorączka i ból gardła. Został on wybrany przez nas ze względu na połączenie tematyki powiązanej z docelowym zbiorem danych dla naszego modelu, jak i brakiem stricte specjalistycznego języka medycznego, w ramach którego modele ASR i embeddingowe powinny poradzić sobie dobrze bez dodatkowego treningu. Drugim wybranym przez nas zbiorem był zbiór FLEURS [fleurs], zawierający szereg zdań wypowiedzianych w 102 językach. Wykorzystaliśmy podzbiory zdań dla języka polskiego i angielskiego, każdy mający około 12 godzin nagrań wraz z ich transkrypcjami, w celu ewaluacji modeli w ramach ich dokładności dla wielu języków.



Rysunek 1: Histogram rozkładu przykładów dla modelu Labse w ramach zbioru *Medical Speech, Transcription, and Intent*. Kolorem pomarańczowym oznaczono ilość zdań, dla których dany przykład jest przykładem negatywnym, niebieskim – pozytywnym

W ramach obliczania metryki MMD (5), skorzystaliśmy z dwóch funkcji jądra $k(x_1, x_2)$:

$$\begin{aligned} \text{Jądro liniowe:} \quad & k_{\text{lin}}(x, y) = x^{\top} y \\ \text{Jądro Gaussowskie (RBF):} \quad & k_{\text{RBF}}(x, y) = \exp \left(- \frac{\|x - y\|_2^2}{2\sigma^2} \right) \end{aligned} \quad (11)$$

Rozkłady przykładów x^n i x^p , dzięki zastosowaniu losowego wyboru były dosyć równomierne dla obu zbiorów danych, co przedstawiono na wykresach 1 i 2.


3.3.2 Implementacja

Eksperymenty zostały przeprowadzone z wykorzystaniem języka Python w wersji 3.12. Modele ASR i embeddingowe wraz z ich wagami zostały pobrane ze strony HuggingFace za pomocą bibliotek *transformers* i *sentence-transformers*. Do szybkiego obliczenia odległości między embeddingami wraz z wyłonieniem najbliższych i najdalszych embeddingów wykorzystaliśmy biblioteki *Pytorch* i *keOps*. Do obliczeń pomocniczych wykorzystaliśmy bibliotekę *numpy*, natomiast do wizualizacji – *matplotlib*. Eksperyment przeprowadzony został na serwerze obliczeniowym przy użyciu karty graficznej Nvidia RTX A5000.


3.3.3 Analiza wyników

Analiza enkodowania znaczenia semantycznego mowy Rozkłady wartości metryki $S(x_{\text{emb}, \text{asr}})$ 4 dla poszczególnych modeli audio przedstawione są na wykresach 3, 4, 5 i 6.


Tabela 1 przedstawia ilość przykładów w ramach zbioru danych *Medical Speech, Transcription, and Intent*, dla których metryka $S(x_{\text{emb}, \text{asr}})$ 4 przyjmowała wartości dodatnie, czyli tam, gdzie model ASR z powodzeniem uchwycił relacje semantyczne. Widać na niej wyraźną




Rysunek 2: Histogram rozkładu przykładów dla modelu Labse w ramach zbioru FLEURS. Kolorem pomarańczowym oznaczono ilość zdań, dla których dany przykład jest przykładem negatywnym, niebieskim – pozytywnym




Rysunek 3: Rozkład wartości różnicy podobieństw dla Data2Vec w ramach zbioru *Medical Speech, Transcription, and Intent*



Rysunek 4: Rozkład wartości różnicy podobieństw dla Wav2Vec w ramach zbioru *Medical Speech, Transcription, and Intent*



Rysunek 5: Rozkład wartości różnicy podobieństw dla Whisper w ramach zbioru *Medical Speech, Transcription, and Intent*



Rysunek 6: Rozkład wartości różnicy podobieństw dla Hubert w ramach zbioru *Medical Speech, Transcription, and Intent*

przewagę modeli Whisper i Hubert, które uchwyciły podobieństwo dla podobnie wysokiej liczby przykładów w ramach tego zbioru danych.


Tabela ?? ilustruje z kolei parametry dopasowanego przez nas rozkładu Student-t dla zagregowanych różnic podobieństwa w ramach wszystkich modeli embeddingowych. Liczba stopni swobody ν odpowiedzialna jest za opisanie stabilności rozkładu w świetle obecności ogonów - im większa, tym bardziej stabilny jest rozkład. Wartości zbliżone do 2, jakie otrzymaliśmy dla modeli Data2Vec, Wav2Vec i Whisper wskazują na ich wysoką niestabilność w uchwyceniu relacji semantycznych. HuBERT okazuje się najbardziej przewidywalnie zachowującym się modelem, dla którego $\nu = 3.6$. Znormalizowana lokalizacja (μ/σ) pozwala nam na porównanie separacji pozytywnych i negatywnych przykładów między ewaluowanymi modelami ASR (MMD nie zachowuje skali pomiędzy modelami). Po raz kolejny, model HuBERT wykazuje się najsilniejszą zdolnością rozróżniania przykładów pozytywnych i negatywnych ($\mu/\sigma = 0.61$), wraz z modelem Whisper plasującym się tuż za nim ($\mu/\sigma = 0.54$). Data2Vec i Wav2Vec przejawiają podobnie niską zdolność dyskryminacji ($\mu/\sigma \approx 0.33$). Ostatnią z badanych metryk jest prawdopodobieństwo prawidłowego uchwycenia relacji między x^a , x^n i x^p . Jest ona podobna do podejścia stricte ilościowego, lecz pozwala ona również analizować osiągi modelu w świetle dopasowanego przez nas rozkładu. Podobnie jak w porównaniu ilościowym, zarówno Whisper jak i HuBERT wykazują najlepsze wyniki. Warto zauważyć jednak, że HuBERT zdecydowanie wysuwa się na prowadzenie w świetle tego porównania, umacniając swoją pozycję jako model najlepiej enkodujący relacje semantyczne w ramach zbioru *Medical Speech, Transcription, and Intent*, dla którego $P(neg > pos) = 71\%$, plasując się przed modelem Whisper, dla którego $P(neg > pos) = 67.8\%$.

Tabela 1: $S(x_{emb,asr}) > 0$ dla zbioru *Medical Speech, Transcription, and Intent* (Ilość przykładów = 5327)


Model	Jina	LaBSE	STSB
HuBERT	3801	3971	3827
Wav2Vec	3352	3377	3472
Data2Vec	3290	3337	3375
Whisper	3848	4006	3802

Wyniki dla dwujęzycznej wersji zbioru Fleurs (język polski i angielski) zostały przedstawione dla modeli ASR wspierających oba z tych języków, reprezentujące trzy rodziny modeli - BeRT (mHuBERT), Whisper i SeamlessM4T. Rozkłady dla tych modeli przedstawione zostały na rysunkach 7, 8 i 9. Tabele ?? i ?? przedstawiają ilościowe porównanie wyników eksperymentu.


Zarówno na podstawie tabeli ?? jak i tabeli ?? zauważyć można dużą przewagę modelu M4T nad pozostałymi modelami. Zarówno umiejętność poprawnej separacji przykładów negatywnych i pozytywnych ($\mu/\sigma = 0.72$), średnia ilość poprawnie przyporządkowanych przykładów ($E[n_{pos}] = 4150$), jak i prawdopodobieństwo poprawnego przyporządkowania przykładów ($P(neg > pos) = 75.3\%$) stawiają SeamlessM4T jako model najlepiej enkodujący semantykę wypowiedzi. Wyniki dla modelu Whisper również wskazują na enkodowanie przez niego znaczenia treści danych wejściowych, z gorszą zdolnością separacji przykładów ($\mu/\sigma = 0.49$) i prawdopodobieństwem prawidłowego ich przyporządkowania ($P(neg > pos) = 68.3\%$), lecz z bardziej stabilnym rozkładem przypadków ($\nu = 10.4$) w porównaniu z SeamlessM4T ($\nu = 6.8$), co wskazuje na zadowalające zdolności modelu Whisper do reprezentacji semantyki danych wejściowych. Zdecydowanie najgorzej wypadł w



Rysunek 7: Rozkład wartości różnicy podobieństw dla Whisper w ramach zbioru *Fleurs*



Rysunek 8: Rozkład wartości różnicy podobieństw dla mHuBERT w ramach zbioru *Fleurs*



Rysunek 9: Rozkład wartości różnicy podobieństw dla M4T w ramach zbioru *Fleurs*

Model	Liczba stopni swobody (ν)	Znormalizowana lokalizacja (μ/σ)	$P(\text{neg} > \text{pos})$
Whisper	1.9	0.54	67.8%
Data2Vec	2.1	0.32	61.1%
Wav2Vec	2.3	0.35	62.1%
HuBERT	3.6	0.61	71.0%

Tabela 2: Parametry rozkładów Student- t dopasowanych do zagregowanych krzywych różnicy podobieństwa dla zbioru *Medical Speech, Transcription, and Intent*

Tabela 3: $S(x_{emb,asr}) > 0$ dla zbioru *Fleurs* (Ilość przykładów = 5443)


Model	Jina	LaBSE	STSB
mHuBERT	3296	3430	3288
M4T	4256	4284	3911
Whisper	3918	3895	3295

tym porównaniu model mHuBERT, który z niskim prawdopodobieństwem poprawnie klasyfikował znaczenie danych wejściowych w świetle ich semantyki ($P(\text{neg} > \text{pos}) = 59.6\%$), osiągając wyniki niewiele większe niż wybór losowy. Możliwą przyczyną tak niskiego wyniku jest niska elastyczność modelu, stworzonego oryginalnie wyłącznie do transkrypcji mowy w języku angielskim, jak i mocy dekodera obecnego w pełnej propagacji w przód modelu. Kolejnym wyjaśnieniem jest zakłócenie oryginalnie silnej reprezentacji semantycznej w modelu angielskim (model HuBERT dla zbioru *Medical Speech, Transcription, and Intent*, tabela ??) przez dotrenowanie na danych ze 146 kolejnych języków, przez które model o tak małej liczbie parametrów – 94.4 miliona – musiał enkodować tekst wejściowy w pewien bardziej skompresowany sposób, nie nadający się do interpretacji w świetle semantyki embeddingów. Hipotezę tę potwierdzają wyniki pracy *Adapting multilingual speech representation model for a new, underresourced language through multilingual fine-tuning and continued pretraining*, w której autorzy zauważyli wyraźnie gorsze wyniki modelu dotrenowanego do transkrypcji języka Ainu na danych w języku angielskim (językowo bardzo różnym od Ainu) [**latentBreakMultilingual**]. Wskazuje to na wysokie prawdopodobieństwo wystąpienia zjawiska zapomnienia (*catastrophic forgetting*), analiza którego nie została umieszczona w oryginalnej pracy autorów mHuBERT-147 [**mhubert**].


Warto zwrócić uwagę na parametr ν opisujący stabilność rozkładu, który największą wartość przyjmuje dla modelu Whisper, w porównaniu do jego wartości dla zbioru *Medical Speech, Transcription, and Intent* - dla zbioru *Fleurs* modele o wiele lepiej radzą sobie z ekstremalnymi przypadkami odległości przykładów *anchor*, *pos* i *neg*. Jest to najprawdopodobniej spowodowane kombinacją dwóch czynników – sztucznej separacji przestrzeni embeddingowej między dwoma językami, która w mniejszym lub większym stopniu jest obecna w każdym z badanych modeli jak i szerszą domeną samego zbioru danych *Fleurs*, który nie skupia się wyłącznie na tematycze medycznej.

Analiza efektu stożka dla wybranych wielojęzycznych modeli ASR Wykresy gęstości podobieństwa kosinusowego dla zbioru *Fleurs* w zależności od języków przedstawione zostały na rysunkach ??, ?? i ??

Widoczny jest tutaj wyraźnie fenomen stożka, zgodny z zależnością zaobserwowaną w oryginalnej pracy [**cone**] – wraz ze wzrostem liczby parametrów i warstw, reprezentacje latentne zajmują coraz to mniejszy fragment przestrzeni (rozkład dla mHuBERT – 94.4 milio-




Rysunek 10: Gęstość podobieństwa kosinusowego z uwzględnieniem języków dla mHuBERT w ramach zbioru *Fleurs*



Rysunek 11: Gęstość podobieństwa kosinusowego z uwzględnieniem języków dla M4T w ramach zbioru *Fleurs*

Model	Liczba stopni swobody (ν)	Znormalizowana lokalizacja (μ/σ)	$P(\text{neg} > \text{pos})$
mHuBERT	2.8	0.27	59.6%
M4T	6.8	0.72	75.3%
Whisper	10.4	0.49	68.3%


Tabela 4: Parametry rozkładów Student- t dopasowanych do zagregowanych krzywych różnicy podobieństwa dla zbioru *Fleurs*




Rysunek 12: Gęstość podobieństwa kosinusowego z uwzględnieniem języków dla Whisper w ramach zbioru *Fleurs*

na parametrów [rysunek ??] a ten sam rozkład dla SeamlessM4T – 2 miliardy parametrów [rysunek ??]). Patrząc na te rozkłady w świetle separacji między grupami językowymi. W celu stwierdzenia, czy klastry dla danych w różnych językach należy spojrzeć na odległość między wykresami gęstości dla podobieństw kosinusowych wewnątrz języków i między językami. Modele mHuBERT i SeamlessM4T wydają się enkodować informacje agnostycznie od języka, z separacją między grupami językowymi będącą wyraźnie najmniejszą dla pierwszego modelu (częściowe pokrycie i niewielkie przesunięcie gęstości między grupami a wewnątrz grup na rysunkach ?? i ??). Model Whisper wykazuje dosyć dużą separację między grupami językowymi w ramach reprezentacji latentnych (rysunek ??). Właściwość ta może prowadzić do mniej dokładnego wyszukiwania informacji między językami polskim i angielskim, a także do gorszego transferu wiedzy pozyskanej w ramach treningu na specjalistycznych zbiorach w języku angielskim do analogicznej wiedzy w języku polskim.


Rysunki ??, ?? i ?? przedstawiają rozkłady gęstości podobieństwa kosinusowego między embeddingami po przekształceniu *All But the Top*. Dla wszystkich modeli, badane reprezentacje latentne zajęły większą część dostępnej przestrzeni. Jest to spowodowane usunięciem pierwszej głównej składowej po analizie PCA, dzięki czemu pewne wspólne informacje przechowywane przez reprezentacje latentne zostały odrzucone, pozostawiając wyłącznie cechy własne charakteryzujące dane wejściowe. Model mHuBERT (rysunek ??) zachował prawie identyczne rozkłady w ramach grup językowych, z gęstością podobieństwa lekko przesuniętą. Wskazuje to na większą separację grup językowych niż w ramach danych nieprzetworzonych (rysunek ??). Może być to spowodowane tendencją modelu do enkodowania informacji dotyczących języka, w niewielkim stopniu, na przykład informacji prozodycznych. Seamless M4T wykazuje się podobną charakterystyką co do przesunięcia podobieństwa



Rysunek 13: Gęstość podobieństwa kosinusowego z uwzględnieniem języków dla MHuBERT w ramach zbioru *Fleurs* po transformacji ABTT



Rysunek 14: Gęstość podobieństwa kosinusowego z uwzględnieniem języków dla M4T w ramach zbioru *Fleurs* po transformacji ABTT




Rysunek 15: Gęstość podobieństwa kosinusowego z uwzględnieniem języków dla Whisper w ramach zbioru *Fleurs* po transformacji ABTT


między grupami, które było obecne również dla danych nieprzetworzonych (rysunki ?? i ??). Warto zwrócić uwagę na różnicę rozkładów wewnątrz grup językowych – embeddingi dla języka polskiego zajmują o wiele większą część przestrzeni niż embeddingi dla języka angielskiego. Naszą hipotezą jest obecność pewnego meta-języka opisującego dane dla modelu M4T, który podobny jest najbardziej do języka angielskiego. O ile autorzy modelu nie podali dokładnego balansu danych między różnymi językami w ramach danych treningowych modelu [m4t], można przypuszczać dominację danych w języku angielskim, stąd też bardziej dokładne reprezentacje danych w języku angielskim. Charakterystyka modelu Whisper (rysunek ??) zaobserwowana dla danych nieprzetworzonych (rysunek ??) została potwierdzona przez rozkłady dla embeddingów po przetworzeniu *All But the Top*. Widoczna jest o wiele bardziej wyraźna separacja na pewne klastry reprezentujące języki polski i angielski. Jest to najprawdopodobniej spowodowane charakterystyką treningu, w ramach której funkcja straty nie wymusza w jakikolwiek sposób współdzielenia przestrzeni latentnej przez dane z różnych języków, dane treningowe dla transkrypcji precyzują język wypowiedzi [whisper].

Rysunki ??, ?? i ?? przedstawiają rozkłady podobieństwa kosinusowego po przeprowadzeniu wybielania (*whitening*). Dzięki dekorrelacji danych w ramach tego procesu, widoczna jest tutaj bliska idealnej umiejętność łączenia języków w jedną grupę, co prowadzi do dobrego transferu wiedzy między językami. Jednakże, w porównaniu z rozkładami dla przetwarzania ABTT, widoczne jest pewne zawężenie przestrzeni embeddingowej – efekt stożka jest bardziej widoczny. Mimo tego, w świetle reprezentacji bazowych, embeddingi zajmują o wiele większy odsetek dostępnej przestrzeni.


Podsumowując, zabieg ABTT zdecydowanie poprawił ogólny rozkład embeddingów w przestrzeni, nie do końca redukując (a dla modelu Whisper pogłębiając) separację między reprezentacjami różnych języków. Wybielanie pozwoliło również na redukcję efektu stożka, tym samym dekorrelując embeddingi w świetle języka, potencjalnie poprawiając transfer wiedzy w ramach treningu na danych w języku angielskim.



Rysunek 16: Gęstość podobieństwa kosinusowego z uwzględnieniem języków dla MHuBERT w ramach zbioru *Fleurs* po wybielaniu



Rysunek 17: Gęstość podobieństwa kosinusowego z uwzględnieniem języków dla M4T w ramach zbioru *Fleurs* po wybielaniu



Rysunek 18: Gęstość podobieństwa kosinusowego z uwzględnieniem języków dla Whisper w ramach zbioru *Fleurs* po wybielaniu

3.4 Wnioski

3.4.1 Porównanie różnic w semantyczności reprezentacji wektorów cech

Analiza różnic między modelami embeddingowymi i generalizacji, które dają modele ASR między modelami embeddingowymi, omówienie relacji między dopasowanym rozkładem beta a ilościami przykładów pozytywnych. Generalizacja między zbiorami danych i kernelami.

3.4.2 Dobór modelu ASR do zintegrowanego systemu przetwarzania mowy i wyszukiwania informacji

Do uzupełnienia po pełnej analizie wyników eksperymentów Na podstawie powyższych wniosków wybrać jeden z proponowanych modeli - Whisper, ewentualnie ewaluować dalej HuBERT, otrzymaliśmy również satysfakcjonujące wyniki. Modele nie modelują idealnie semantyki, lecz whisper i hubert radzą sobie dobrze z relacjami (emergent semantic representations).

4 Ewaluacja architektur dopasowania reprezentacji latentnych modeli ASR i modeli embeddingowych

4.1 Założenia teoretyczne

4.1.1 Translacja reprezentacji latentnych modeli do wspólnej przestrzeni

Istniejące techniki linear translation, dodatkowe bardziej zaawansowane

4.1.2 Modele multimodalne i wymuszenie semantycznych reprezentacji danych

Contrastive, triplet loss

4.2 Metodologia

4.2.1 Wykorzystane modele ASR i embeddingowe

Powtórzenie wniosków z poprzedniego rozdziału, dobór modelu embeddingowego

4.2.2 Model agregujący uwagę *Attention Pool Model* wykorzystujący uczenie nadzorowane

Omówienie architektury, motywacja, przebieg treningu

4.2.3 Model oparty o translację reprezentacji latentnych *Semantic Alignment Model* wykorzystujący uczenie nienadzorowane

Omówienie architektury, motywacja, przebieg treningu

4.2.4 Wykorzystane techniki uczenia nienadzorowanego Data2Vec we wstępnym treningu

Omówienie wykorzystania Data2Vec dla każdego z powyższych modeli

4.2.5 Ewaluacja proponowanych modeli

Metryki i sposoby ewaluacji pozwalające na jednolite porównanie modeli.

4.3 Eksperymenty

4.3.1 Założenia projektowe

Wykorzystane zbiory danych, warianty modeli

4.3.2 Implementacja

Opis wykorzystanych narzędzi

4.3.3 Analiza wyników

Porównanie stabilności treningu, wpływ Data2Vec na jakość modeli

4.4 Wnioski

4.4.1 Ewaluacja architektury *Attention Pool Model*

Omówienie, porównanie wariantów, wnioski dotyczące zachowania i generalizacji

4.4.2 Ewaluacja architektury *Semantic Alignment Model*

Omówienie, porównanie wariantów, wnioski dotyczące zachowania i generalizacji

4.4.3 Potencjalne osiągi modeli w kontekście pełnego systemu wyszukiwania

Zarysowanie powyższych wniosków w realiach systemu wyszukiwania

5 System wyszukiwania informacji z wykorzystaniem architektury dopasowania reprezentacji latentnych modeli ASR i modeli embeddingowych

5.1 Architektura systemu

5.1.1 Moduł indeksowania dokumentów

Diagram parsowania dokumentów i indeksowania w systemie

5.1.2 Indeks dokumentów

Wykorzystane indeksy - tiered index oparty o ilość cytowań, zone index dla abstractów i treści dokumentów

5.1.3 Przetwarzanie zapytania

Diagram sekwencji i działania

5.1.4 Interfejs użytkownika

Omówienie działania, zrzuty ekranu interfejsu, omówienie przykładowego workflow

5.2 Ewaluacja jakości systemu przez użytkownika

5.2.1 Metryki jakości pozyskanych danych

Omówienie precision, recall, F1

5.2.2 Ewaluacja oceny zwracanej przez użytkownika

Algorytm Roccio, LLM jako użytkownik końcowy przesyłający oceny, potencjalna ewaluacja przez rzeczywistego użytkownika

5.3 Porównanie modeli w kontekście systemu wyszukiwania informacji

5.3.1 Metodologia

Opis metod porównania i metryk

5.3.2 Ewaluacja systemów bez informacji zwrotnych od użytkownika

Porównanie modeli

5.3.3 Ewaluacja systemów wraz z informacją zwrotną od użytkownika

Porównanie modeli

5.3.4 Porównanie wykorzystania zasobów i prędkości wyszukiwania

Benchmarki pamięci i prędkości wyszukiwania end to end

5.4 Wnioski

Plusy i minusy naszego rozwiązania i klasycznego rozwiązania opartego o transkrypcje

5.4.1 Porównanie modeli dla wyszukiwania bez informacji zwrotnych

Plusy i minusy każdego łącznie z osiągnięciami

5.4.2 Porównanie modeli dla wyszukiwania wraz z informacją zwrotną od użytkownika

Plusy i minusy każdego łącznie z osiągnięciami

5.5 Wybór najlepszej architektury systemu do potencjalnego wykorzystania w warunkach klinicznych

Ewaluacja wszystkich powyższych wniosków

6 Podsumowanie

6.1 Semantyczność reprezentacji modeli ASR

Omówienie wniosków, multi-lingual vs angielski, generalizacja i charakterystyki, wpływ rodzaju treningu na reprezentacje

6.2 Proponowane architektury modeli modelujących semantykę audio

6.2.1 Architektura *Attention Pool Model*

Omówienie, reiteracja wniosków, wpływ Data2Vec

6.2.2 Architektura *Semantic Alignment Model*

Omówienie, reiteracja wniosków, wpływ Data2Vec

6.3 Proponowane rozwiązania w kontekście stworzonego systemu wyszukiwania

Omówienie wniosków, porównanie wpływu informacji zwrotnej od użytkownika końcowego

6.4 Potencjalne kierunki rozwoju proponowanego rozwiązania

Omówienie dalszego rozwoju, inne modele embeddingowe, usprawnienia systemu wyszukiwania, rozszerzenie modalności (zdjęcia)

Dodatki